КАЗАХСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ имени К. И. Сатпаева

Тема:

«Подход машинного обучения для анализа преступности. Методы и модели поиска и анализа криминально значимой информации в неструктурированных и слабоструктурированных текстовых массивах»

Выполнил: Mussa Akbota

Big Data Analytics and Mining for Crime Data Analysis, Visualization and Prediction

Mingchen Feng^{1,2}, Jiangbin Zheng^{1(⋈)}, Yukang Han², Jinchang Ren², and Qiaoyuan Liu^{2,3}

School of Computer Science, Northwestern Polytechnical University, Xi'an, China mingchen. feng@strath.ac.uk, zhengjb@nwpu.edu.cn

Department of Electronic and Electrical Engineering, University of Strathclyde, Glasgow, UK {yukang.han, jinchang.ren, qiaoyuan.liu}@strath.ac.uk

Department of Information Science and Technology, Northeast Normal University, Changchun, China

Abstract. Crime analysis and prediction is a systematic approach for analyzing and identifying different patterns, relations and trends in crime. In this paper we conduct exploratory data analysis to analyze criminal data in San Francisco, Chicago and Philadelphia. We first explored time series of the data, and fore-

Investigating Crimes using Text Mining and Network Analysis

Nael T. Elyezjy
The Islamic University of Gaza
Department of Postgraduate Studies
Faculty of Information Technology
Gaza, Palestine

ABSTRACT

In these days, security of citizens is considered one of the major concerns of any government in the world. In every country, there is a huge amount of unstructured texts coming from investigating offenders in police departments. As a result, the importance of crime analysis is growing day after day.

There is a little research; in methods and techniques that extract criminal networks from unstructured investigations texts especially in Arabic language. In our proposed system, we climb three main distinct contributions to discover forensics using investigation documents. The first by extracting offender names from unstructured text. Secondly, by constructing a crime network from real Arabic investigation documents. Finally, we provide analysis of the interaction between offenders in different documents that directly and indirectly related used to discover a new clue used to solve the crime puzzle. To evaluate the performance and effectiveness of the proposed system, real unstructured documents about investigations are obtained from police departments in the Gaza Strip. The experimental results show that the proposed question is affective in identifying proper

Alaa M. Elhaless
The Islamic University of Gaza
Department of Postgraduate Studies
Faculty of Information Technology
Gaza, Palestine

Unstructured text is very common. According to Gupta et al. over 80% of information is stored as texts [7]. Many police departments have a huge amount of investigations as unstructured text that can be useful to detect and prevent a new crime accident by identifying crime patterns. Text mining techniques played a vital role in the last few years in knowledge extraction from unstructured documents, especially in crime detection and prevention. [8].

The number of publications and research projects in data mining in the law enforcement area is slowly increasing [9]. Most of the tools and software used by police departments utilizes structured databases which are easy for investigators to compute some statistics about the crime, or search for particular information about crime. But unstructured documents of previous investigations are usually saved in an archive. [10, 11].

Arabic language is one of the most widely spoken languages in the world. As far as it is known, there is a little research that focus on crime domain in Arabic language. The first goal of the current study is to develop a system for extracting useful information in the Arabic crime domain from Home Catalogue Open Data Data Analytics Maps Crime @ a Glance Strategy Terms of Use FAQ

The Public Safety Data Portal is intended to improve the understanding of policing, improve transparency and enhance confidence through the creation and use of open data for public safety in Toronto.

What's New

Major Crime Indicators (MCI) Updates

Homicide Open Data

New Dashboard - Shootings Historical

New - Open Data Catalogue

New Data Update: Major Crime Indicators (MCI) Open Data has been updated to include 2018 data.

Download 2004-2018 Data

View Interactive Dashboard

Major Crime

Akbota Mussa

Crime analysis

```
In [1]: import pandas as pd
          import numpy as np
          from arcgis.gis import GIS
 In [ ]: import collections
          import matplotlib.pyplot as plt
          from mpl_toolkits.basemap import Basemap # Needs to be configured if running basemap package
          from arcgis.gis import GIS
In [133]: from mpl_toolkits.basemap import Basemap
          import mpl toolkits
 In [4]: df = pd.read_csv('MCI_2014_to_2017.csv')
 In [5]: df.head()
 Out[5]:
```

:		X	Υ	Index_	event_unique_id	occurrencedate	reporteddate	premisetype	ucr_code	ucr_ext	C
	0	-79.520401	43.768829	14601	GO- 20142775022	2014-08- 25T04:00:00.000Z	2014-08- 25T04:00:00.000Z	Outside	1430	100	£
	1	-79.580856	43.642574	14602	GO- 20142870874	2014-08- 25T04:00:00.000Z	2014-09- 08T04:00:00.000Z	House	2120	220	E V
	2	-79.260445	43.762909	14603	GO- 20142802386	2014-08- 25T04:00:00.000Z	2014-08- 29T04:00:00.000Z	House	1430	100	£
	3	-79.367546	43.663208	14604	GO- 20142777955	2014-08- 25T04:00:00.000Z	2014-08- 26T04:00:00.000Z	Commercial	2120	200	Е
	4	-79.231758	43.776440	14605	GO- 20142778699	2014-08- 25T04:00:00.000Z	2014-08- 26T04:00:00.000Z	Other	2120	200	Е

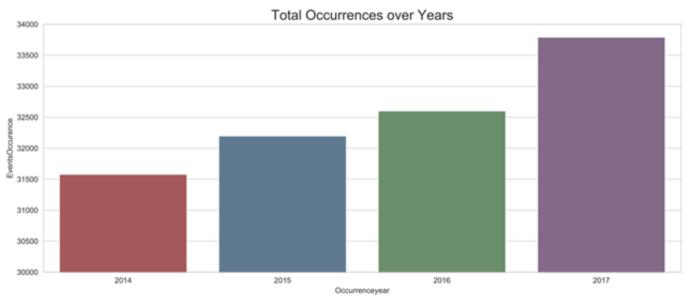
Out[5]:

:	yofyear	occurrencedayofweek	occurrencehour	MCI	Division	Hood_ID	Neighbourhood	Lat	Long	FID
		Monday	18	Assault	D31	24	Black Creek (24)	43.768829	-79.520401	14001
		Monday	9	Break and Enter	D22	11	Eringate- Centennial-West Deane (11)	43.642574	-79.580856	14002
		Monday	11	Assault	D41	127	Bendale (127)	43.762909	-79.260445	14003
		Monday	17	Break and Enter	D51	71	Cabbagetown- South St.James Town (71)	43.663208	-79.367546	14004
		Monday	16	Break and Enter	D43	137	Woburn (137)	43.776440	-79.231758	14005

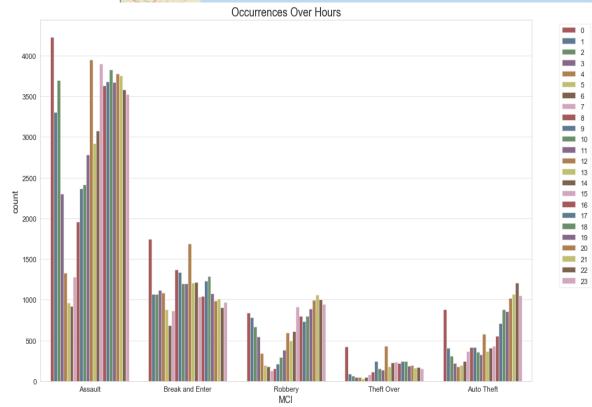
4

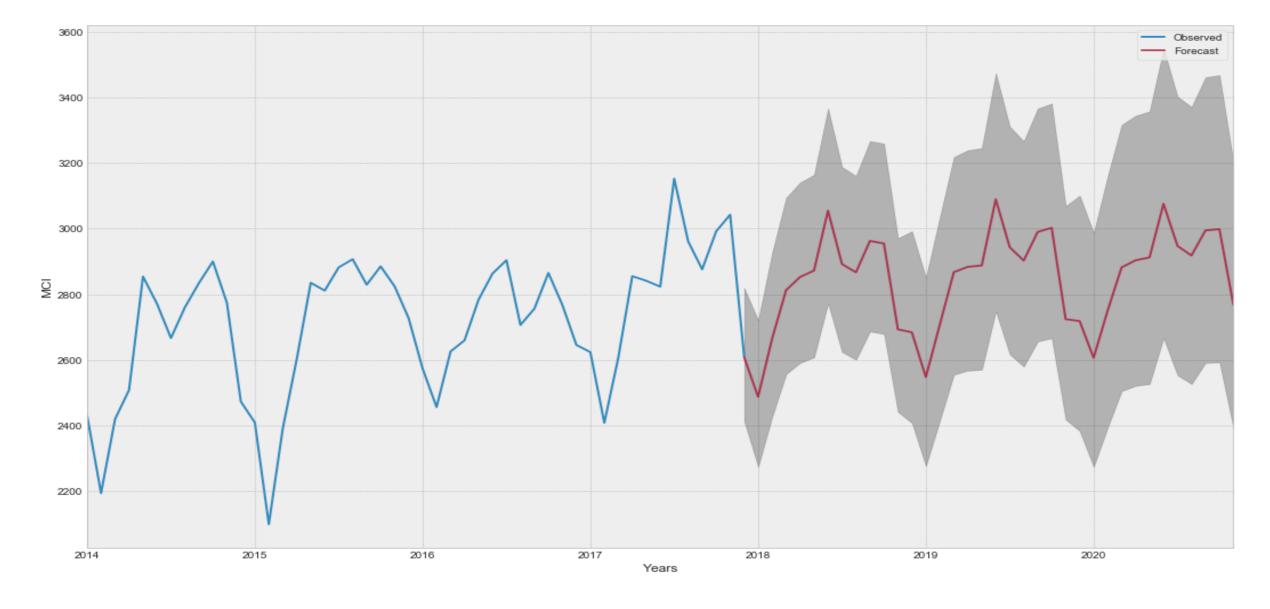
In [6]: df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 131073 entries, 0 to 131072
Data columns (total 29 columns):









ARIMA MODEL

•6. Результаты	Accuracy	Log-loss
Algorithm		
Decision Tree Classifier	56.79%	1.054
Gaussian Naive Bayes	55.24%	1.107
K-Nearest Neighbor	58.64%	1.023
Logistic Regression	58.98%	1.007
Random Forest Classifier	60.79%	0.98

DATA SOURCES

Google Ads

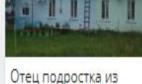
1117

лықтар





жия: что и



Ульяновской области

Дала өрті кезінде мерт болған үш азаматқа медаль берілді

Одан бөлек өртті өшіремін деп зардап шеккен 7 азамат ҚР Ішкі істер министрлігі атынан "Өрт сөндірудегі көрсеткен ерлігі үшін" медалімен марапатталды.



Көп оқылғанд

- 1 "Үнсіз жылай береді. Алматыда 12 жасар і шешесінің көңілдесі
- Ақтөбелік келіншек баласын жерлеуге ан таппай, елден көмек
- 3 бір адамды жүз айналдырып,
- **4** қызметінен босатыл
- Премьер-министр қы

Барлық соңғы жаңалықтар

```
2019-08-18
2019-08-17
22:27 Nur Otan-да екі аудандағы АӘК-тің таратылуындағы заң бұзушылықтар қаралды
18:16 Асқар Мамин Арыс қаласын қалпына келтіру жұмыстарын және Түркістандағы құрылыс нысандарын текс
15:25 Түркістанда шығыстық үлгідегі автобекет ашылды
2019-08-16
20:21 Бүгін арыстықтар 100 мың теңге жәрдемақыны алды 💽
17:54 АҚШ-тың санкциялары Ресейдің мұнайына деген сұранысты байқаусызда өсіріп жіберді
17:37 Елбасы алдағы сайлауға партиялардың даярлық жұмысын жеделдетуді тапсырды 🗩 2
16:50 "Бір шындықты айтайын...". Димаш Қадыр атасының ескі видеосын парақшасына жүктеді 🗖
16:25 2-3 сағат босқа тұрады. Линейканың керегі не? 🗩 2
16:03 Дала өрті кезінде мерт болған үш азаматқа медаль берілді
     Білім министрі Аймағамбетов "Әліппенің" былығын айтты
```

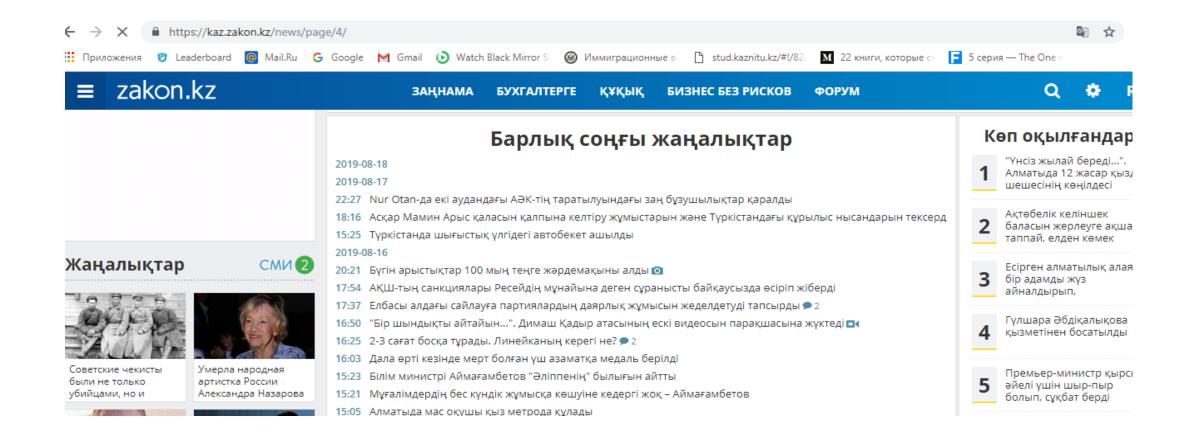
Tokenization

Tokenization segments a document into its atomic elements. In this case, we are interested in tokenizing to words. First we need to break the sentence in to words. This process is called **tokenization**

```
In [33]: sentence = df["title"][0]
         sentence
Out[33]: 'Nur Otan-да екі аудандағы АӘК-тің таратылуындағы заң бұзушылықтар қаралды'
         tokens = nltk.wordpunct_tokenize(sentence)
In [34]:
         tokens
Out[34]: ['Nur',
           'Otan',
           'да',
           'екі',
           'аудандағы',
           'ΑƏΚ',
           '-',
           'тің',
           'таратылуындағы',
           'заң',
           'бұзушылықтар',
           'қаралды']
```

Число крупных преступлений за последние годы

	title	date	url	tokens
0	Nur Otan-да екі аудандағы АӘК-тің таратылуында	22:27 2019-08- 17	https://kaz.zakon.kz/news/4981980-nur-otan- da	nur,otan,да,екі,аудандағы,аәк <mark>,тің</mark> ,таратылуында
1	Асқар Мамин Арыс қаласын қалпына келтіру жұмыс	18:16 2019-08- 17	https://kaz.zakon.k 2Y1ews/4981981-As-a r- mamin	асқар,мамин,арыс,қаласын,қалпына,келтіру,жұмыс
2	Түркістанда шығыстық үлгідегі автобекет ашылды	15:25 2019-08- 17	https://kaz.zakon.kz/news/4981963-t-rk- standa	түркістанда,шығыстық,үлг <mark>і</mark> дегі,автобекет,ашылды
3	Бүгін арыстықтар 100 мың теңге жәрдемақыны алды	20:21 2019-08- 16	https://kaz.zakon.kz/news/4981913-b-g-n- arysty	бүгін,арыстықтар,100,мың,теңге,жәрдемақыны,алды
4	АҚШ-тың санкциялары Ресейдің мұнайына деген сұ	17:54 2019-08- 16	https://kaz.zakon.kz/news/4981898-a-sh-ty- sank	ақш,тың,санкциялары,ресейдің,мұнайына,деген,сұ







Пусть они найдут вас.

Google Ads

Жаңалықтар



«Стыдные» удовольствия: что и зачем мы делаем Отец подростка из Ульяновской области рассказал о сыне:

CMM 2





Дала өрті кезінде мерт болған үш азаматқа медаль берілді

Одан бөлек өртті өшіремін деп зардап шеккен 7 азамат ҚР Ішкі істер министрлігі атынан "Өрт сөндірудегі көрсеткен ерлігі үшін" медалімен марапатталды.



Көп оқылғандар

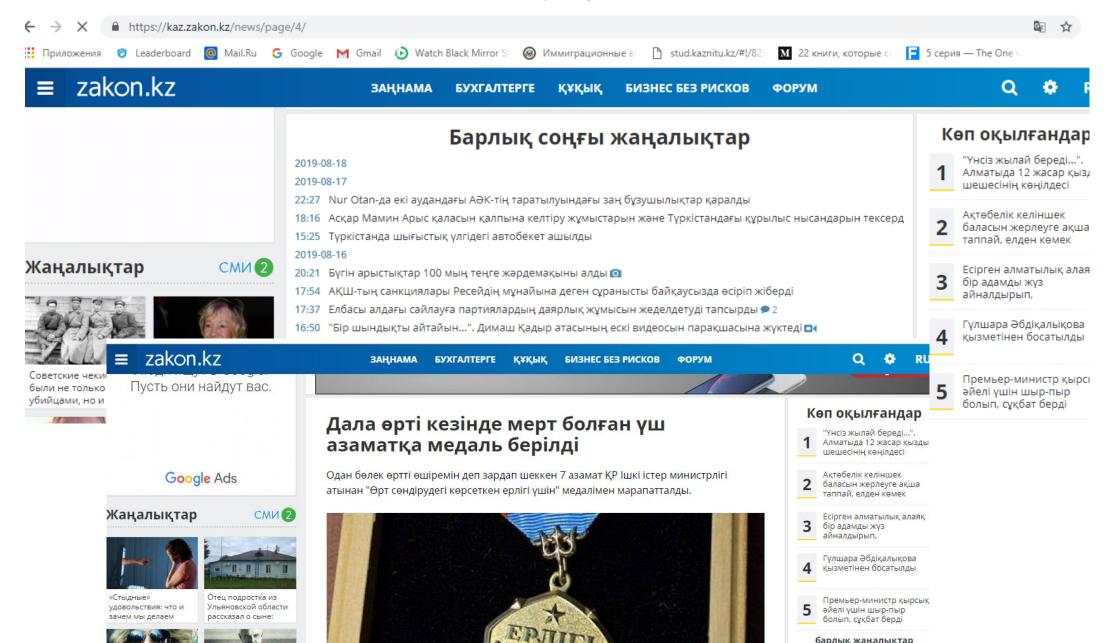
- "Үнсіз жылай береді...". Алматыда 12 жасар қызды шешесінің көңілдесі
- 2 Ақтөбелік келіншек баласын жерлеуге ақша таппай, елден көмек
- 3 Есірген алматылық алаяқ бір адамды жүз айналдырып,
- Гүлшара Әбдіқалықова қызметінен босатылды
- Премьер-министр қырсық әйелі үшін шыр-пыр болып, сұқбат берді

барлык жаналыктар

Молель ARIMA

```
In [1]: import requests
        from bs4 import BeautifulSoup
        import re
        import pandas as pd
In [2]: base_url = "https://kaz.zakon.kz/news"
In [3]: def get_element(elem, tag_name):
            result = elem.select(tag_name)[0].get_text()
            return result
        def get_href(elem):
            result = elem.select('a')[0].get_attribute_list("href")[0]
            return result
In [5]: # neshe kunnin janalygy kerek ekenin osy jerde korsetesin
        days_count = 10
In [6]: urls = []
        for i in range(1, days_count + 1):
            urls.append(f'{base_url}/page/{i}/')
In [7]: urls
AUTETIC FILES IN
```

Web Scraping & NLP



Tools: BeautifulSoup

```
In [1]: import requests
        from bs4 import BeautifulSoup
        import re
        import pandas as pd
In [2]: base url = "https://kaz.zakon.kz/news"
In [3]: def get_element(elem, tag_name):
            result = elem.select(tag_name)[0].get_text()
            return result
        def get_href(elem):
            result = elem.select('a')[0].get_attribute_list("href")[0]
            return result
In [5]: # neshe kunnin janalygy kerek ekenin osy jerde korsetesin
        days count = 10
In [6]: urls = []
        for i in range(1, days_count + 1):
            urls.append(f'{base_url}/page/{i}/')
In [7]: urls
```

RESULTS: getting readable dataframe

```
In [11]: df = pd.DataFrame.from dict(cleaned news)
           df.head()
In [12]:
Out[12]:
                                                            title
                                                                             date
                                                                                                                             url
                 Nur Otan-да екі аудандағы АӘК-тің таратылуында...
                                                                                    https://kaz.zakon.kz/news/4981980-nur-otan-da-...
                                                                  22:27 2019-08-17
               Асқар Мамин Арыс қаласын қалпына келтіру жұмыс...
                                                                  18:16 2019-08-17
                                                                                   https://kaz.zakon.kz/news/4981971-as-ar-mamin-...
                   Туркістанда шығыстық үлгідегі автобекет ашылды
                                                                                     https://kaz.zakon.kz/news/4981963-t-rk-standa-...
                                                                  15:25 2019-08-17
                Бүгін арыстықтар 100 мың теңге жәрдемақыны алды
                                                                  20:21 2019-08-16
                                                                                     https://kaz.zakon.kz/news/4981913-b-g-n-arysty...
              АҚШ-тың санкциялары Ресейдің мұнайына деген сұ... 17:54 2019-08-16
                                                                                    https://kaz.zakon.kz/news/4981898-a-sh-ty-sank...
           df.shape
In [13]:
Out[13]: (135, 3)
           df.to_csv('last_news_final.csv', encoding="utf8", index=False)
```

Creating a Wordcloud

- let us visually see which are the words that are most prominent. This
 requires us to find all the words in the `title` and create a frequency
 count for how many times the word occurs.
- Tokenization segments a document into its atomic elements. In this case, we are interested in tokenizing to words.
- First we need to break the sentence in to words. This process is called
 tokenization

Tokenization

Tokenization segments a document into its atomic elements. In this case, we are interested in tokenizing to words. First we need to break the sentence in to words. This process is called **tokenization**

```
In [33]: sentence = df["title"][0]
          sentence
Out[33]: 'Nur Otan-да екі аудандағы АӘК-тің таратылуындағы заң бұзушылықтар қаралды'
In [34]: tokens = nltk.wordpunct_tokenize(sentence)
          tokens
Out[34]: ['Nur',
           'Otan',
          '-',
'да',
           'екі',
           'аудандағы',
          'AƏK',
          'тің',
          'таратылуындағы',
          'заң',
          'бұзушылықтар',
          'қаралды']
```

```
df['tokens'] = df.apply(generate_word_frequency,axis=1)
```

df.head()

	title	date	url	tokens
0	Nur Otan-да екі аудандағы АӘК-тің таратылуында	22:27 2019-08- 17	https://kaz.zakon.kz/news/4981980-nur-otan-da	nur,otan,да,екі,аудандағы,аәк,тің,таратылуында
1	Асқар Мамин Арыс қаласын қалпына келтіру жұмыс	18:16 2019-08- 17	https://kaz.zakon.kz/news/4981971-as-ar- mamin	асқар,мамин,арыс,қаласын,қалпына,келтіру,жұмыс
2	Түркістанда шығыстық үлгідегі автобекет ашылды	15:25 2019-08- 17	https://kaz.zakon.kz/news/4981963-t-rk- standa	түркістанда,шығыстық,үлгідегі,автобекет,ашылды
3	Бүгін арыстықтар 100 мың теңге жәрдемақыны алды	20:21 2019-08- 16	https://kaz.zakon.kz/news/4981913-b-g-n- arysty	бүгін,арыстықтар,100,мың,теңге,жәрдемақыны,алды
4	АҚШ-тың санкциялары Ресейдің мұнайына деген сұ	17:54 2019-08- 16	https://kaz.zakon.kz/news/4981898-a-sh-ty- sank	ақш,тың,санкциялары,ресейдің,мұнайына,деген,сұ

Results from wordcloud:



Tag | Meaning | English Examples

Tag	Meaning	Examples
ADJ	adjective	new, good, high, special, big, local
ADP	adposition	on, of, at, with, by, into, under
ADV	adverb	really, already, still, early, now
CONJ	conjunction	and, or, but, if, while, although
DET	determiner	the, a, some, most, every, no, which
NOUN	noun	year, home, costs, time, Africa
NUM	numeral	twenty-four, fourth, 1991, 14:24
PRT	particle	at, on, out, over per, that, up, with
PRON	pronoun	he, their, her, its, my, I, us
VERB	verb	is, say, told, given, playing, would
0	punctuation marks	1,11
×	other	ersatz, esprit, dunno, gr8, univeristy

We already have POS tags - now all we need is chunking

The basic technique we will use for entity detection is chunking, which segments and labels multi-token sequences as illustrated in 2.1. The smaller boxes show the word-level tokenization and part-of-speech tagging, while the large boxes show higher-level chunking. Each of these larger boxes is called a chunk. Like tokenization, which omits whitespace, chunking usually selects a subset of the tokens. Also like tokenization, the pieces produced by a chunker do not overlap in the source text.



Named Entity-Type	Examples
ORGANIZATION	Georgia-Pacific Corp., WHO
PERSON	Eddy Bonte, President Obama
LOCATION	Murray River, Mount Everest
DATE	June, 2008-06-29
TIME	two fifty a m, 1:30 p.m.
MONEY	175 million Canadian Dollars, GBP 10.40
PERCENT	twenty pct, 18.75 %
FACILITY	Washington Monument, Stonehenge
GPE	South East Asia, Midlothian

Results: tag, pos tag

100	ì

title	date	url	tokens	stem	lemma	pos_tags	named_entities
-да екі і АӘК- тің інда	22:27 2019- 08-17	https://kaz.zakon.kz/news/4981980- nur-otan-da	nur,otan,да,екі,аудандағы,аәк,тің,таратылуында	nur otan-да екі аудандағы аәк- тің таратылуында	Nur Otan-да екі аудандағы АӘК- тің таратылуында	[(Nur, NNP), (Otan, NNP), (-, :), (да, NN), (е	[Nur Otan, AƏK]
Ламин пасын елтіру мыс	18:16 2019- 08-17	https://kaz.zakon.kz/news/4981971- as-ar-mamin	асқар,мамин,арыс,қаласын,қалпына,келтіру,жұмыс	асқар мамин арыс қаласын қалпына келтіру жұмыс	Асқар Мамин Арыс қаласын қалпына келтіру жұмыс	[(Асқар, ЈЈ), (Мамин, NNP), (Арыс, NNP), (қала	[Асқар Мамин Арыс]
танда ыстық лгідегі обекет ылды	15:25 2019- 08-17	https://kaz.zakon.kz/news/4981963- t-rk-standa	түркістанда,шығыстық,үлгідегі,автобекет,ашылды	түркістанда шығыстық үлгідегі автобекет ашылды	Түркістанда шығыстық үлгідегі автобекет ашылды	[(Түркістанда, JJ), (шығыстық, NNP), (үлгідегі	[Түркістанда]
Бүгін ар 100 і теңге ақыны алды	20:21 2019- 08-16	https://kaz.zakon.kz/news/4981913- b-g-n-arysty	бүгін,арыстықтар,100,мың,теңге,жәрдемақыны,алды	бүгін арыстықтар 100 мың теңге жәрдемақыны алды	Бүгін арыстықтар 100 мың теңге жәрдемақыны алды	[(Бүгін, ЈЈ), (арыстықтар, \$), (100, CD), (мың	0
Ш-тың ялары сейдің деген сұ	17:54 2019- 08-16	https://kaz.zakon.kz/news/4981898- a-sh-ty-sank	ақш,тың,санкциялары,ресейдің,мұнайына,деген,сұ	ақш-тың санкциялары ресейдің мұнайына деген сұ	АҚШ-тың санкциялары Ресейдің мұнайына деген сұ	[(АҚШ, SYM), (-, :), (тың, NN), (санкциялары, 	[АҚШ, Ресейдің]
4							b

Content of the news

```
art_text4 = article_body.getText().replace('\n',' ')
art_text4
```

Пойызда жолаушыны зорлаған жолсеріктер сотталды Қостанай қаласының №2 соты "Тұлпар-Тальго" пойызында қыз зорлаған жолсерікте р Жетес Үмбеталиев пен Қолқанат Құрманиязовты ҚР Қылмыстық кодексінің 120 бабы, 1 бөлімі бойынша айыпты деп танып, әрқайсысын 2 жыл 6 айдан бас бостандығынан айыру туралы үкім шығарды. Олар жазасын қылмыстық атқару жүйесінің қауіпсіздік деңгейі орташа мек емесінде өтейді. Сотталғандарды сот залынан қамауға алды. Браконьерлер қолынан қаза тапқан қорықшының ордені отбасына табысталд ы Жезқазған қаласында "Охотзоопром" кәсіпорнының инспекторы К.Нұртазиновты соңғы сапарға шығарып салды. Президенттің жарлығымен К.Нуртазиновке берілген І дәрежелі "Айбын" орденін маркумның жубайына Қарағанды облысының әкімі Е.Кошанов пен Экология министрі М.Мырзағалиев табыстады. Облыс әкімі Президент тапсырмасымен Ұлытау ауданындағы көшелердің біріне қорықшының есімі берілетінін мәлімдеді. Арыстағы апат жайында фильм түсірілді "Арыс 24.06" деп аталатын фильмде Арыс қаласындағы әскери қоймаларда болған жа рылыста халықтың бастан өткерген қиын сәттері көрсетілген. Бейнематериалда апат аумағына бірінші боп жеткен өрт сөндірушілер ті лсіз жауды қалай ауыздықтағаны туралы айтса, олардың туған-туыстары да төтенше оқиға күнгі көңіл-күйлерінен сыр шертеді. Машина жасаушылар одағы Шүкеевтің мәлімдемесіне жауап берді Түркістан облысының әкімі Ө.Шүкеев Бәйдібек ауданына жұмыс сапары барысынд а отандық ауылшаруашылығы техникаларын өндірушілерді алаяқтарға теңеген. Машина жасаушылар одағы облыс әкімінің мұндай мәлімдем есі отандық өндірушілердің абыройына нұқсан келтіріп қоймай, мемлекеттің индустрияландыру саясатына деген сенімді жоғалтады дег ен пікір білдірді. Өтініш авторлары өткен жылы "АгромашХолдинг" АҚ-на келгенде Ауылшаруашылығы министрлігінің басшылары керісін ше салаға жоғары баға бергенін айтып, таңқалып отыр. Машина жасаушы кәсіпорындардың биылғы жылдың бірінші тоқсанында 553 млрд т еңгенің өнімін өндіргені аталды. Одақтағылар Шукеевтің айтқан субсидияның ауылшаруашылығы машиналарын жасаушыларға тіпті берілм егенін айтып қалды. Қауіпсіздік сертификатын орнату қауіпті ме? ҰҚК мемлекеттік техникалық қызмет директорының орынбасары Зекен Исмайыловтың айтуынша, сертификат тек қана шифрланған трафиктің мағынасын ашу үшін, сондай-ақ деструктивті контенттер мен парақ шаларды бұғаттау үшін қолданылады. Қауіпсіздік комитетінің өкілі сертификат арқылы ешкімнің әлеуметтік желідегі пароліне, парақ шасына, хат-хабарламаларына қол сұғылмайтынын мәлім етті. Осы орайда қауіпсіздік сертификатының техникалық тұрғыда VPN-ды бұғат тай алатынын айтып қалды. Сөзіне сенсек, қауіпсіздік сертификатының көмегімен VPN-ды бұғаттау үшін соттың шешімі немесе құзірет ті мемлекеттік органның нұсқауы қажет. – Баспасөзді оқығанда Facebook, Twitter желілерінде проблемалар барын жиі байқаймыз. Қаз ақстанда жиі болмаса да, бәрібір болады. Байланыс операторларымен тұрақты байланыстамыз. Туындаған мәселенің барлығымен жұмыс і стейміз Сонлыктан оларлын жауапкершілігіне катысты мәселе болса байланыс операторының саll-орталығына жүсінүінізлі сураймыз. Ө

Sentiment analysis of text

```
processed_text = TextBlob(art_text4)
print(processed_text.sentiment)
```

Sentiment(polarity=-0.425, subjectivity=0.55)